

COMITE DE CLASSIFICADORES

Predicao de churn em clientes de telecomunicacoes

Universidade: Universidade Sao Judas Tadeu

Disciplina: Inteligencia Artificial

Integrantes: [Preencher nomes dos integrantes]

Professor(a): [Preencher nome do(a) professor(a)]

Turma: [Preencher turma]

Sao Paulo

2026

Resumo

Este projeto desenvolveu um pipeline de aprendizado supervisionado para prever o cancelamento de clientes de uma empresa de telecomunicacoes. Foram treinados quatro classificadores individuais - KNN, Naive Bayes, SVM e Arvore de Decisao - e um comite por votacao suave. O comite apresentou o melhor F1-score (0,6205), superando o melhor modelo individual (Naive Bayes, com 0,5928), e demonstrou melhor equilibrio entre precisao e recall.

Palavras-chave: classificacao; ensemble; churn; aprendizado supervisionado; inteligencia artificial.

1. Introducao

A perda de clientes, conhecida como churn, representa um problema relevante para empresas de servicos recorrentes. Identificar antecipadamente clientes com maior risco de cancelamento permite direcionar campanhas de retencao, melhorar o atendimento e reduzir perdas de receita.

O objetivo deste trabalho e aplicar tecnicas de aprendizado supervisionado na construcao de um comite de classificadores. O desempenho do comite e comparado ao desempenho de modelos individuais, utilizando metricas adequadas para uma base com classes desbalanceadas.

2. Descricao da base de dados

Foi utilizada a base publica Telco Customer Churn, disponibilizada na plataforma Kaggle. Cada linha representa um cliente e cada coluna descreve caracteristicas demograficas, servicos contratados, cobranças e situacao de cancelamento.

Caracteristica	Descricao
Registros	7.043 clientes
Colunas	21 colunas no arquivo original
Target	Churn: Yes para cancelamento e No para permanencia
Features numericas	SeniorCitizen, tenure, MonthlyCharges e TotalCharges
Features categoricas	Genero, contrato, servicos, pagamento e outras




Figura 1 - Distribuicao da variavel alvo. Fonte: elaboracao propria.

A classe positiva corresponde a 1.869 clientes (26,54%), enquanto 5.174 clientes (73,46%) não cancelaram. Esse desbalanceamento torna insuficiente avaliar os modelos apenas pela acurácia.

3. Definicao do problema

O problema foi definido como uma classificação binária. A variável alvo é Churn, convertida para 1 quando o cliente cancelou e 0 quando permaneceu. As variáveis independentes incluem tempo como cliente, cobrança mensal, cobrança total, tipo de contrato, forma de pagamento e serviços contratados.

Em termos de inferência, o modelo busca identificar quais clientes apresentam maior risco de cancelamento com base em seus atributos. A classe positiva é o churn, pois representa o evento de maior interesse para uma estratégia de retenção.

4. Pre-processamento

O pre-processamento foi implementado por meio de pipelines para evitar vazamento de dados. As principais etapas foram:

- Conversão de TotalCharges de texto para valor numérico, revelando 11 valores ausentes.
- Imputação dos valores numéricos ausentes pela mediana.
- Remoção de customerID, pois a coluna identifica clientes, mas não explica churn.
- Codificação one-hot das variáveis categóricas.
- Padronização das variáveis numéricas com StandardScaler.

- Separacao estratificada em 80% para treino e 20% para teste.

A divisao resultou em 5.634 registros de treino e 1.409 de teste. Depois da codificacao, cada conjunto passou a possuir 45 atributos e nenhum valor ausente.

5. Modelagem dos classificadores individuais

Foram selecionados quatro algoritmos com diferentes formas de aprendizado. O uso de modelos diversos e importante para a construcao do comite, pois cada algoritmo pode reconhecer padroes distintos nos dados.

Modelo	Configuracao e finalidade
KNN	Classificacao pelos 11 vizinhos mais proximos.
Naive Bayes	Modelo probabilistico gaussiano, simples e sensivel aos sinais de churn.
SVM	Kernel RBF com calibracao de probabilidades.
Arvore de Decisao	Profundidade maxima 6 e minimo de 20 amostras por folha.

Todos os modelos foram treinados no mesmo conjunto e avaliados no mesmo conjunto de teste, mantendo uma comparacao justa. O pre-processamento foi ajustado somente com dados de treino.

6. Construcao do comite

O comite foi construido por votacao suave (soft voting), combinando KNN, Naive Bayes, SVM e Arvore de Decisao. Nessa estrategia, cada classificador calcula probabilidades para as classes. O comite utiliza a media dessas probabilidades e escolhe a classe com maior valor final.

A votacao suave foi escolhida porque considera o grau de confianca de cada classificador, em vez de utilizar apenas a classe prevista. A combinacao busca equilibrar modelos com perfis diferentes de precisao e recall.

7. Resultados e metricas

Modelo	Acuracia	Precisao	Recall	F1-score
Comite	0,7743	0,5603	0,6952	0,6205
Naive Bayes	0,6948	0,4589	0,8369	0,5928
KNN	0,7779	0,5822	0,5775	0,5799
Arvore de Decisao	0,7970	0,6679	0,4679	0,5503
SVM	0,7935	0,6627	0,4519	0,5374

Tabela 1 - Comparacao dos modelos no conjunto de teste. Fonte: elaboracao propria.




Figura 2 - Comparacao das metricas. Fonte: elaboracao propria.

8. Discussao

A Arvore de Decisao apresentou a maior acuracia individual (0,7970), mas identificou apenas 46,79% dos clientes que realmente cancelaram. Esse resultado mostra por que a acuracia isolada pode ser enganosa em bases desbalanceadas.

O Naive Bayes apresentou o maior recall (0,8369), identificando a maior parte dos clientes com churn. Entretanto, sua precisao de 0,4589 indica maior quantidade de falsos alertas. O comite reduziu esse desequilibrio: atingiu recall de 0,6952, precisao de 0,5603 e o melhor F1-score, 0,6205. Assim, o comite apresentou melhora sobre o melhor classificador individual segundo o criterio principal adotado.

8.1 Limitacoes

- Os resultados representam uma unica divisao entre treino e teste.
- Os hiperparametros foram definidos de forma inicial, sem uma busca extensa.
- A base nao informa o momento exato do cancelamento nem os custos das acoes de retencao.
- O desbalanceamento influencia o comportamento dos classificadores.

8.2 Melhorias futuras

- Aplicar validacao cruzada e busca de hiperparametros.
- Avaliar pesos diferentes para cada integrante do comite.
- Testar tecnicas de balanceamento e ajuste do limiar de classificacao.
- Incluir metricas como curva ROC, AUC e curva precisao-recall.
- Investigar interpretabilidade e importancia das features.

9. Conclusao

O projeto cumpriu o objetivo de construir um pipeline completo de classificacao, desde a analise e preparacao dos dados ate a avaliacao de modelos individuais e de um comite. Os resultados confirmaram que modelos com maior acuracia nem sempre sao os mais adequados para identificar clientes em risco de cancelamento.

O comite por votacao suave apresentou o melhor F1-score e um equilibrio superior entre precisao e recall. Portanto, para o problema proposto, a combinacao dos classificadores foi mais adequada do que a utilizacao isolada dos modelos avaliados.

Referencias

KAGGLE. Telco Customer Churn. Disponivel em: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>. Acesso em: 9 jun. 2026.

SCIKIT-LEARN DEVELOPERS. Scikit-learn: machine learning in Python. Disponivel em: <https://scikit-learn.org/>. Acesso em: 9 jun. 2026.