

ROTEIRO DE EXPLICACAO DO PROJETO

Comite de classificadores para previsao de churn

1. Qual problema meu projeto resolve?

Meu projeto tenta prever quais clientes de uma empresa de telecomunicacoes possuem maior risco de cancelar o servico. Esse cancelamento e chamado de churn. Identificar esses clientes antecipadamente pode ajudar a empresa a criar acoes de retencao, oferecer melhores condicoes e evitar perdas de receita.

A tarefa e um problema de classificacao binaria: o cliente pertence a classe Churn = Yes quando cancelou e Churn = No quando permaneceu.

2. O que meu projeto faz?

O projeto analisa os dados dos clientes, prepara esses dados para uso por algoritmos de inteligencia artificial, treina quatro classificadores diferentes e depois combina os modelos em um comite. Por fim, compara o desempenho dos modelos para descobrir qual abordagem apresenta o melhor resultado.

- Carrega e analisa uma base publica do Kaggle com 7.043 clientes.
- Trata valores ausentes e transforma variaveis categoricas em numeros.
- Separa os dados entre treino e teste.
- Treina KNN, Naive Bayes, SVM e Arvore de Decisao.
- Combina os quatro modelos em um comite por votacao suave.
- Avalia acuracia, precisao, recall, F1-score e matrizes de confusao.

3. Como eu fiz o projeto

1. Escolhi a base Telco Customer Churn no Kaggle porque ela possui uma variavel alvo clara e representa um problema real de classificacao.
2. Defini Churn como target e removi customerID, pois o identificador nao ajuda a prever cancelamento.
3. Analisei a distribuicao do target e observei que a base e desbalanceada: existem mais clientes que nao cancelaram.
4. Converti TotalCharges para numero e tratei seus 11 valores ausentes usando a mediana.
5. Codifiquei as variaveis categoricas com one-hot encoding e padronizei as variaveis numericas.
6. Dividi os dados de forma estratificada: 80% para treino e 20% para teste.
7. Treinei e avaliei os quatro classificadores no mesmo conjunto de teste.
8. Criei um comite por votacao suave, que calcula a media das probabilidades previstas pelos modelos.

4. Por que usei um pipeline?

Utilizei pipelines para unir o pre-processamento e o classificador. Isso garante que as mesmas transformacoes sejam aplicadas corretamente aos dados e evita vazamento de dados, pois o pre-processamento e ajustado somente com o conjunto de treino.

5. Classificadores utilizados

Modelo	Como funciona de forma resumida
KNN	Classifica usando os clientes mais parecidos e proximos.
Naive Bayes	Calcula probabilidades com base nas caracteristicas observadas.
SVM	Procura uma fronteira que separe as classes.
Arvore de Decisao	Cria regras e decisoes sucessivas sobre as features.
Comite	Combina as probabilidades dos quatro modelos.

6. Como avaliar os resultados

- Acuracia: percentual total de previsoes corretas.
- Precisao: entre os clientes previstos como churn, quantos realmente cancelaram.
- Recall: entre os clientes que cancelaram, quantos foram identificados.
- F1-score: equilibrio entre precisao e recall.
- Matriz de confusao: mostra acertos e erros para cada classe.

Como a base e desbalanceada, escolhi o F1-score como principal criterio de comparacao. Uma acuracia alta pode esconder o fato de que o modelo nao identifica os clientes que realmente cancelam.

7. Resultados obtidos

Modelo	Acuracia	Precisao	Recall	F1-score
Comite	0,7743	0,5603	0,6952	0,6205
Naive Bayes	0,6948	0,4589	0,8369	0,5928
KNN	0,7779	0,5822	0,5775	0,5799
Arvore	0,7970	0,6679	0,4679	0,5503
SVM	0,7935	0,6627	0,4519	0,5374

O melhor modelo individual pelo F1-score foi o Naive Bayes, com 0,5928. O comite obteve F1-score de 0,6205 e apresentou melhora sobre todos os modelos individuais. A Arvore teve a maior acuracia, mas um recall baixo, mostrando que acuracia isolada nao e suficiente.

8. O que mostrar ao professor

- Abrir o notebook 01_eda_preprocessamento.ipynb e mostrar o carregamento da base, os graficos e o tratamento dos dados.
- Mostrar que o pre-processamento terminou com 45 atributos e zero valores ausentes.
- Abrir o notebook 02_modelagem_comite.ipynb e mostrar a definicao dos quatro modelos.
- Executar o notebook e mostrar a tabela de metricas e as matrizes de confusao.
- Finalizar mostrando que o comite atingiu F1-score 0,6205, superior ao melhor modelo individual.

9. Fala curta para a demonstracao

"O problema escolhido foi prever o churn de clientes de telecomunicacoes. Primeiro, analisei e preparei a base, tratando valores ausentes, codificando categorias e padronizando valores numericos. Depois, treinei quatro classificadores diferentes e criei um comite por votacao suave. Como a base e desbalanceada, utilizei principalmente o F1-score para comparar os modelos. O melhor modelo individual foi o Naive Bayes, com F1-score de 0,5928, enquanto o comite atingiu 0,6205. Portanto, a combinacao dos classificadores apresentou o melhor equilibrio geral."

10. Limitacoes e proximos passos

- Os modelos foram avaliados em uma unica divisao de treino e teste.
- Os hiperparametros podem ser melhorados com busca automatizada.
- O comite pode testar pesos diferentes para cada classificador.
- Podem ser avaliadas tecnicas de balanceamento e interpretabilidade.